

# Asset Allocation

Projeto de Asset Allocation (Mestrado Profissional de Economia)

Início do desenvolvimento: 25/06/2024

## Funcionalidades:

O projeto apresenta duas funcionalidades.

### 1. **BackTest**

Para rodar o back test, basta rodar o comando:

```
python src/main.py plot_asset_returns
```

### 2. **Plot Asset Returns**

Para rodar o back test, basta rodar o comando:

```
python src/main.py plot_asset_returns
```

## Estrutura do Projeto

Na pasta `data`, temos os inputs usados para rodar o código (na pasta `data/input`) e na pasta `data/output` encontramos os resultados e as configurações dos backtests, bem como as figuras salvas do plots.

Na pasta `docs`, encontramos alguns documentos que podem explicar melhor quais as contas foram feitas, além de outras referências úteis.

- [Lógica para calcular retornos de swaps](#)
- [Lógica para calcular vol. de cada ativo](#)
- [Lógica para calcular vol. das estratégias](#)
- [Lógica da estratégia de Vol. Targeting](#)
- [Lógica da estratégia de Trend-Following](#)
- [Lógica de controle do trading book como um todo](#)

Na pasta `src`, encontramos todo o código usado nesse projeto. De forma geral, a pasta `src/presentation` contempla toda a parte do código que é usada para criar gráficos. Na pasta `src/core` está implementada a lógica principal do código.

## Arquitetura de Software

Para desenvolver esse trabalho, o modelo de **Clean Architecture** foi usado como inspiração para a arquitetura de software. Dessa forma, o código salvo em `src/core`, apresenta a seguinte segmentação por camadas:

- **APPLICATION** : onde estão implementadas as classes que são responsáveis pela lógica geral da aplicação. É onde encontramos a implementação da atualização da *trading position* das assets, a implementação das *trading strategies* e do *trading book* como um todo.
- **DOMAIN** : onde estão implementadas as entidades como resultados dos tradings, swaps e o portfolio. Além disso, também está implementadas cálculos comumente conhecidos, a transformação de taxas anuais para uma taxa diária.
- **INFRA** : onde estão implementadas as classes que são responsáveis pela conexão com os dados (no caso, a planilha .csv em `input`).

## Dependências

As dependências para esse projeto estão listadas no arquivo `requirements.txt`. Para instalá-las usando pip, basta escrever no terminal:

```
pip install -r requirements.txt
```

As libs externas usadas nesse projeto são:

```
ipython==8.12.3  
matplotlib==3.7.5  
numpy==1.23.5  
pandas==1.1.3  
plotly==5.8.0
```

# Cálculo de retorno dos Swaps

O retorno diário do swap é dado por:

$$r_t^{Swap} = r_t^{ETF} - r_t^{short} \quad (1)$$

Dessa forma, usando como base o preço do *total return index (gross dividends)* ( $p_t$ ) dos ETFs usados, calculamos o log-retorno diário dos ETFs como:

$$r_t^{ETF} = \log(p_t) - \log(p_{t-1}) \quad (2)$$

```
import pandas as pd
import numpy as np
def calculate_log_return(df : pd.DataFrame, price_col : str):
    return np.log(df[price_col]) - np.log(df[price_col].shift(1))
```

A base da **LIBOR** (índice usado na perna short do swap) foi dado em taxa anual, inicialmente precisamos transformar a taxa anual em taxa diária e em seguida transformar em log-retorno:

$$r_t^{\text{daily-log-return}} = \log((1 + r_t^{\text{annual}})^{1/365}) \quad (3)$$

```
import pandas as pd
import numpy as np
def transform_annual_rate_in_daily_log_raturnd(df : pd.DataFrame, annual_rate_col: str):
    df2 = df.reset_index()
    return np.log((1 + df2[annual_rate_col])** (1/365))
```

Com isso, os log-retornos diários dos swaps das ETFs ( $r_t^{Swap}$ ) foram calculados.

# Cálculo da Volatilidade

O cálculo da vol de cada asset e a vol. da estratégia é primordial para o controle geral das estratégias e para a execução individual de cada estratégia, tanto na vol-targeting como na implementação usada pela trend-following.

O cálculo de cada componente está descrito abaixo. Para todas, o número de pontos  $n$  usados para o cálculo da vol. foi definido como 90 (embora pudesse ser definido um número diferente para cada estratégia e book).

## 1. Swaps

### 1.1. Swaps - Cálculo da volatilidade

Dado a série histórica dos [log-retornos dos swaps](#) usados em uma determinada estratégia, obtemos os últimos  $n$  pontos antes da data  $t$  e calculamos o desvio padrão de cada swap:

$$V_t^{Swaps} = Std[R_{t-n-1 \leq d < t}^{Swaps}] \quad (1)$$

```
def get_assets_volatility(self, target_date, last_n_points):  
    df = self.log_returns[self.log_returns[ias.DATE] < target_date].tail(last_n_points)  
    std = df[self.asset_names].std()  
    return std
```

### 1.2. Swaps - Cálculo da covariância

Dado a série histórica dos log-retornos dos swaps usados em uma determinada estratégia, obtemos os últimos  $n$  pontos antes da data  $t$  e a matriz de covariância:

$$COV_t^{Swaps} = Cov[R_{t-n-1 \leq d < t}^{Swaps}] \quad (2)$$

```
def get_covariance_matrix(self, target_date, last_n_points):  
    df = self.log_returns[self.log_returns[ias.DATE] < target_date].tail(last_n_points)  
    covariance_matrix = df[self.asset_names].cov()  
    return covariance_matrix
```

## 2. Estratégias

### 2.1. Estratégias - Cálculo da volatilidade

Em determinada data  $t$ , um swap (ou asset, para generalizar) possui uma posição  $w_{a,t}$  em determinada estratégia, sendo que cada posição pode variar entre  $-\lambda_{max} \leq w_{a,t} \leq \lambda_{max}$ , onde  $\lambda_{max}$  é a máxima alavancagem (*leverage*) permitida para essa estratégia.

Uma posição  $w_{a,t} > 0$  significa que a estratégia está long no swap e uma posição  $w_{a,t} < 0$  significa que a estratégia está short no swap.

Sendo uma estratégia com  $k$  swaps, o vetor de posições para cada swap usado nessa estratégia é definido por:

$$W_t = \begin{bmatrix} w_{1,t} \\ w_{2,t} \\ \vdots \\ w_{k,t} \end{bmatrix}^T \quad (3)$$

Assim, dado o vetor de posições da estratégia e a matriz de covariância dos log-retornos dos swaps  $COV_t^{Swaps}$ , a volatilidade da estratégia é dada por:

$$V_t^{Estratégia} = \sqrt{W_t \times COV_t^{Swaps} \times W_t^T} \quad (4)$$

```
def get_portfolio_volatility(self, target_date, last_n_points):
    covariance = self.get_covariance_matrix(target_date, last_n_points)

    # calculando vol da estratégia
    current_asset_weights_series = pd.Series(self.current_asset_weights)
    portfolio_var = current_asset_weights_series @ covariance @ current_asset_weights_
    portfolio_vol = np.sqrt(portfolio_var)

    return portfolio_vol
```

### 3. Vol. do Trading Book

O Trading Book é formado por um conjunto de estratégias e o peso em cada estratégia pode mudar ao longo do tempo. Nesse sentido, uma estratégia possui um peso  $\rho_{s,t}$  no book, sendo que:

$$\begin{cases} \sum_{s=1}^m \rho_{s,t} = 1 & \forall t \\ 0 \leq \rho_{s,t} \leq 1 & \forall t, \end{cases} \quad (5)$$

onde  $m$  é o número de estratégias. Com isso, o vetor de pesos para cada estratégia no book é definido por:

$$P_t = \begin{bmatrix} \rho_{1,t} \\ \rho_{2,t} \\ \vdots \\ \rho_{m,t} \end{bmatrix}^T \quad (6)$$

Para calcular a matriz de correlação das estratégias, usamos como *proxy* do log-retorno o P&L diário da estratégia, desconsiderando a média de P&L diário dos últimos  $n$  dias.

Nesse sentido, para uma data  $t$ , a covariância das estratégias  $COV_t^{Estratégias}$  seria dada por:

$$COV_t^{Estratégias} = Cov[(PnL_{t-n-1 \leq d < t}^{Estratégias}) - \mathbb{E}(PnL_{t-n-1 \leq d < t}^{Estratégias})] \quad (7)$$

Assim, sendo o vetor de pesos das estratégias  $P_t$  e a matriz de covariância dos pnls diários das estratégias  $COV_t^{Estratégias}$ , a volatilidade do book é dada por:

$$V_t^{Book} = \sqrt{P_t \times COV_t^{Estratégias} \times P_t^T} \quad (8)$$

```
def calc_portfolio_volatility_with_weights(self, target_date, last_n_points, current_as
    covariance = self.get_covariance_matrix(target_date, last_n_points)

    # calculando vol do book
    portfolio_var = current_asset_weights @ covariance @ current_asset_weights.T
    portfolio_vol = np.sqrt(portfolio_var)

    return portfolio_vol
```